


CLUSTERIZAÇÃO DE BASE DE VINHOS (K-MEANS)

CIÊNCIA DE DADOS; NOTURNO

TEORIA DO APRENDIZADO ESTATÍSTICO

ANDRÉ KOGA E MARCOS VINICIUS SOKABE RIBEIRO


As variáveis Fenóis e Flavonoides foram escolhidas para a análise de clusterização com base em sua alta correlação positiva observada na matriz de correlação. Com uma correlação de 0.86, elas apresentam uma forte relação linear, o que indica que ambas as variáveis se comportam de maneira semelhante em termos de variação dentro dos dados. Isso faz com que elas sejam adequadas para uma análise conjunta, já que capturam características similares da composição química dos vinhos.



Embora em muitas análises de clustering seja recomendada a minimização de sobreposição entre variáveis, o uso de variáveis fortemente correlacionadas como Fenóis e Flavonoides pode ser interessante quando buscamos identificar padrões específicos de comportamento em um subconjunto de dados. Nesse caso, a análise dessas duas variáveis juntas permite identificar clusters baseados em propriedades relacionadas ao perfil químico dos vinhos, mais especificamente em compostos fenólicos que impactam diretamente o sabor, cor e astringência do vinho. Ao aplicar o algoritmo K-means com essas duas variáveis, os vinhos foram divididos em três grupos distintos.

Clusters distintos: Cada cluster capturou grupos de vinhos com diferentes perfis em relação aos teores de fenóis e flavonoides. Isso sugere que os vinhos podem ser separados em categorias com base nessas propriedades químicas, o que pode estar relacionado a diferentes tipos de vinhos ou técnicas de vinificação.

Centróides dos clusters: Os centróides dos clusters representam o ponto médio em termos de fenóis e flavonoides para cada grupo, indicando o perfil médio de cada cluster. Vinhos com níveis mais altos ou mais baixos desses compostos estão agrupados de acordo com semelhanças químicas.



A escolha das variáveis Fenóis e Flavonoides foi baseada em sua forte correlação, o que torna esses atributos ideais para a análise de similaridade entre os vinhos. A clusterização revelou padrões interessantes, sugerindo que essas características têm um papel importante na diferenciação dos vinhos, possivelmente refletindo diferenças em sabor, estrutura e qualidade.

Código de clusterização

```
import pandas as pd

import matplotlib.pyplot as plt

from sklearn.cluster import KMeans

from sklearn.preprocessing import StandardScaler

file_path = 'C:/Users/vini/Downloads/vinhos_x.csv'

df_vinhos = pd.read_csv(file_path)

X = df_vinhos[['Phenols', 'Flavanoids']]

scaler = StandardScaler()

X_scaled = scaler.fit_transform(X)

kmeans = KMeans(n_clusters=3, random_state=42)

kmeans.fit(X_scaled)

df_vinhos['Cluster'] = kmeans.labels_

plt.figure(figsize=(8, 6))

plt.scatter(X_scaled[:, 0], X_scaled[:, 1], c=kmeans.labels_, cmap='viridis')

plt.scatter(kmeans.cluster_centers_[:, 0], kmeans.cluster_centers_[:, 1], s=200, c='red', label='Centroids', marker='X')

plt.title('Clusters com Phenols e Flavanoids')

plt.xlabel('Phenols (Fenóis)')

plt.ylabel('Flavanoids')

plt.legend()

plt.show()
```